


Amostragem e Discretização



- Aula 15 -
Coleta, Preparação e
Análise de Dados

Prof. Me. Lucas R. C. Pessutto



PUCRS

Pontifícia Universidade Católica
do Rio Grande do Sul



Slides adaptados do material do Prof. Lucas Silveira
Kupssinskü e do Prof. Luan Fonseca Garcia

Amostragem

- O processo de amostragem consiste em selecionar apenas um **subconjunto** dos dados para fazer alguma análise
- A motivação para amostrar dados em data mining é diferente da estatística
 - As vezes re-amostramos os dados apenas devido aos requerimentos de processamento e memória.

Amostragem

- Queremos amostras *representativas*
 - Propriedades semelhantes às do conjunto de dados
- Como amostragem é um processo estatístico, precisamos escolher a forma de amostrar que melhor vai manter as *características* que tentamos analisar.

Tipos de Amostragem

- Amostragem Aleatória Simples
 - Com ou sem reposição

Alguém consegue pensar em um caso onde essa abordagem não é adequada?

Tipos de Amostragem


- Amostragem Aleatória Simples
 - Com ou sem reposição
- Amostragem Estratificada
 - Mantendo ou não a proporção dos estratos (normalmente definidos artificialmente)
- Amostragem por Conglomerado
 - Mantendo ou não a proporção dos conglomerados (grupos)

Amostragem Estratificada

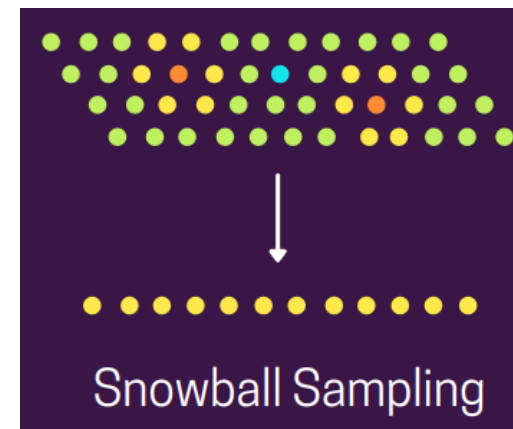

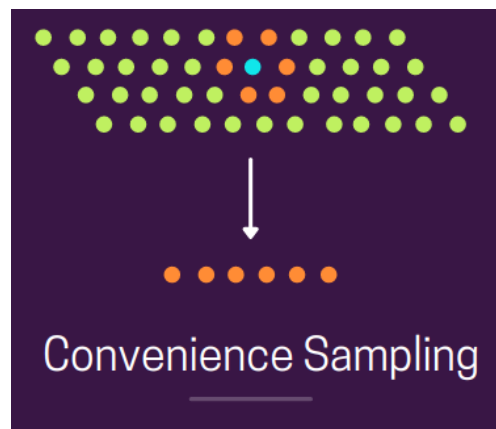



Strata (Age)	Number of People in Population	Number To Be Included in Sample
20-24	30,000	150
25-29	70,000	350
30-34	40,000	200
35-39	30,000	150
40-44	20,000	100
>44	10,000	50
Total	200,000	1,000

Amostragem Estratificada


- Amostragem Estratificada Proporcional
 - Usada quando queremos manter a proporção dentro dos estratos.
- Amostragem Estratificada Desproporcional
 - Utilizada em conjuntos de dados desbalanceados.



Resumo



SAMPLING BIAS



" WE RECEIVED 500 RESPONSES AND
FOUND THAT PEOPLE LOVE RESPONDING
TO SURVEYS "

sketchplanations

Binarização e One-hot Encoding


Valor Categórico	Valor Inteiro	Valores Binarizados			One-Hot Encoding				
		x_1	x_2	x_3	x_1	x_2	x_3	x_4	x_5
Péssimo	0	0	0	0	0	0	0	0	1
Ruim	1	0	0	1	0	0	0	1	0
Regular	2	0	1	0	0	0	1	0	0
Bom	3	0	1	1	0	1	0	0	0
Ótimo	4	1	0	0	1	0	0	0	0

Observação: Eventualmente pode ser necessário codificar um único atributo binário como duas *features* assimétricas. Por exemplo para codificar o sexo de uma pessoa. A representação binária assimétrica é ineficiente em termos de custo de memória.


Discretização de atributos contínuos

- Envolve dois passos:
 - Decidir um número de categorias para dividir o atributo;
 - Definir uma função de mapeamento do valor contínuo para uma categoria.
- Podemos representar a discretização usando uma série de intervalos:
 $\{(k_0, k_1], (k_1, k_2], \dots, (k_{n-1}, k_n)\}$


Discretização de atributos contínuos



(a) Original data.



(b) Equal width discretization.



(c) Equal frequency discretization.

Atributos categóricos com muitas variações

- Caso um atributo categórico possua muitos valores pode ser necessário diminuir o número de categoriais;
 - Para variáveis ordinais podemos aplicar “discretização”;
 - Para variáveis nominais temos que aplicar algum conhecimento de domínio.

Exercício Avaliativo

- (Amostragem) Escreva o corpo da função mostrada abaixo:

```
amostragem_aleatória(dataframe, amostras, reposicao=True)
```

Essa função recebe três parâmetros:

- dataframe = pandas contendo os dados
- amostras = número de amostras desejadas
- reposicao = amostragem com ou sem reposição

Essa função deve retornar um dataframe com o número exato de amostras

Não pode usar as funções de amostragem prontas do pandas!

Exercício Avaliativo

- (Amostragem) Escreva uma função com a assinatura mostrada abaixo:

`amostragem_estratificada(dataframe, amostras, coluna)`

Essa função recebe três parâmetros:

- dataframe = pandas contendo os dados
- amostras = número de amostras desejadas
- coluna = nome de uma coluna do dataset

Essa função deve retornar um dataframe com o número exato de amostras, mantendo a proporção de valores da coluna escolhida presente no dataframe original.

Não pode usar as funções de amostragem prontas do pandas!

Exercício Avaliativo

- Exemplo:

Dataset Entrada (100 registros)

Valor da Coluna	Qtde Valores
A	50
B	30
C	10
D	20

Dataset Saída (10 registros)

Valor da Coluna	Qtde Valores
A	5
B	3
C	1
D	2

Exercício Avaliativo

- Usando o dataset “alugueis” fornecido, realize testes nas funções desenvolvidas:
 - Crie um dataset com apenas 100 amostras
 - Crie outro dataset com 200 amostras, preservando a proporção de imóveis em cada cidade
- Faça a discretização do atributo área do imóvel em três categorias:
 - “PEQUENO” = até 50m²
 - “MÉDIO” = 50 até 100m²
 - “GRANDE” = > 100m²
- Divida o atributo total em 5 categorias e utilize one-hot encoding para discretizá-lo